

# 周宇航

手机：(+86) 18851822106 · 邮箱：yuhangzhou@smail.nju.edu.cn

个人主页：<https://njuzyh.github.io> · 住址：江苏省南京市

## 教育背景

南京大学，计算机学院，博士（硕博连读）	2021.09 - 至今
<ul style="list-style-type: none"><li>• 导师：田臣教授</li><li>• 研究方向：机器学习系统、数据中心网络</li></ul>	
南京大学，计算机科学与技术系，本科	2016.09 - 2020.06

## 实习经历

华为计算产品线，实习生	2023.01 - 2024.12
<ul style="list-style-type: none"><li>• 大模型训练/推理的性能建模与优化</li><li>• 大模型训练容错</li></ul>	
鹏城实验室，实习生	2022.06 - 2022.12
<ul style="list-style-type: none"><li>• 基于鹏城云脑 2 的大模型训练性能 profiling 和瓶颈分析</li></ul>	

## 发表论文

<b>Squeezing Operator Performance Potential for the Ascend Architecture.</b> ASPLOS'25	CCF-A
<ul style="list-style-type: none"><li>• 第一作者</li></ul>	
<b>Accelerating Model Training on Ascend Chips: An Industrial System for Profiling, Analysis and Optimization.</b> ATC'25	CCF-A
<ul style="list-style-type: none"><li>• 第一作者</li></ul>	
<b>Chameleon: Adaptive Fault Tolerance for Distributed Training via Real-time Policy Selection.</b> INFOCOM'26	CCF-A
<ul style="list-style-type: none"><li>• 第一作者</li></ul>	
<b>PushBox: Making Use of Every Bit of Time to Accelerate Completion of Data-parallel Jobs.</b> IEEE TPDS	CCF-A
<ul style="list-style-type: none"><li>• 合作作者</li></ul>	
<b>MEET: rack-level pooling based load balancing in datacenter networks.</b> IEEE TPDS	CCF-A
<ul style="list-style-type: none"><li>• 合作作者</li></ul>	

## 项目经历

基于昇腾芯片架构的算子性能建模与优化	2024.03 - 2024.10
<ul style="list-style-type: none"><li>• 提出“组件”抽象，描述 Ascend 芯片中计算与数据传输单元的串并行执行特性。</li><li>• 设计并实现面向 Ascend 架构的组件级 Roofline 模型，显著提升瓶颈分析的准确性。</li><li>• 完成多个真实的算子优化案例，支持训练/推理场景，涵盖 11 个模型，算子加速比高达 2.15 倍。</li><li>• 本人负责核心思想提出、建模实现、部分实验验证及论文撰写，论文已被 ASPLOS'25 接收。</li></ul>	
大模型训练性能瓶颈定位与分析	2023.01 - 2024.12
<ul style="list-style-type: none"><li>• 提出新的 profiling 机制，包括轻量级 monitor 和细粒度 profiler，采集完整的性能指标应对性能波动。</li><li>• 设计分层瓶颈分析框架，先进行算子间并行分析，再深入算子内分析瓶颈原因，全面准确地识别并行、I/O、CPU、计算和通信瓶颈。</li><li>• 基于 135 个典型瓶颈案例，开发出优化工具 mstt advisor，自动检测瓶颈原因并提供优化建议。</li><li>• 本人负责分层瓶颈分析的设计，瓶颈成因分析总结，实验验证和撰写论文，论文已被 ATC'25 接收。</li></ul>	

大模型训练容错	2025.01 - 2025.07
<ul style="list-style-type: none"> <li>提出自适应容错，实时策略选择实现训练的高效故障恢复，解决现有无备份方法的性能局限。</li> <li>构建统一性能模型，结合解析建模与 <b>profiling</b>，预估执行时间和内存占用，为策略选择提供理论支撑。</li> <li>启发式执行计划搜索，考虑并行度、数据分配、模型层划分等因素，在控制开销的同时快速寻优。</li> <li>将权重传输抽象为二分图匹配问题，将非对称同步通信建模为图着色问题，降低状态迁移开销和单步执行时间。</li> <li>本人负责 Chameleon 系统的核心设计、实验验证及论文撰写，论文已被 INFOCOM'26 接收。</li> </ul>	

云数据中心网络数据分析及建模	2021.10 - 2022.09
<ul style="list-style-type: none"> <li>基于 NS3 仿真平台对 DLRM 模型训练通信进行建模，发现 NCCL 路径选择对训练性能有显著影响。</li> <li>全面分析 NCCL 参数空间和对通信的影响，结合随机森林和模拟退火算法实现自动化 NCCL 配置。</li> <li>本人主要负责 NS3 通信建模、自动化 NCCL 配置核心算法的提出、部分 NCCL 通信实验验证等工作。</li> </ul>	

### 荣誉奖励

博士生国家奖学金	2025.10
南京大学优秀研究生标兵	2025.12